TP2 : estimation de l'âge à partir des visages via des CNN et Transfer Learning

Réalisé par : KENGNI MBOU Emilie Kevine

Partie 1 : CNN entrainé from scratch

Question 1 : Le ScratchCNN atteint une MAE test de 13,35 ans contre La baseline qui donne une MAE test de 14,39 ans. Il n'est pas utilisable en pratique car il a peu appris (1,04 an de moins que la baseline), il se trompe encore de plus de 13 ans en moyenne, ce qui est trop pour être utile.

Question 2 : Sur la figure From-scratch CNN, les courbes train et val sont quasiment superposées. Il n'y a pas de surapprentissage mais du sous-apprentissage avec environ 4000 images, le réseau n'a pas pu apprendre des filtres discriminants pour l'âge. Les CNN profonds s'appuient sur ImageNet, soit près de 1,2 million.

Expérience 1 : comparaison de 3 approches

Question1 : En observant la figure From-scratch vs. Transfer Learning, on note que le ResNet fine-tuné est mieux que le ResNet gelé, qui est lui-même mieux que le CNN from scratch. Ce classement confirme ce qu'on a vu en cours le transfert bat l'entraînement from scratch, et le fine-tuning bat l'extraction de caractéristiques lorsque le domaine diffère, alors qu'ImageNet contient surtout des objets. On note aussi que la qualité des features pré-entraînées compte plus que le nombre de paramètres appris, ResNet gelé n'entraîne que 513 paramètres et fait mieux que le CNN from scratch, qui en entraîne 405 889.

Question 2 : Débloquer le réseau a fortement aidé la MAE test passe de 12,52 à 8,86 ans, soit 3,66 ans de moins. Mais avec seulement 4000 images, on voit bien le risque du fine-tuning sur un grand réseau à 11,2 millions de paramètres, à l'epoch 20, on a MAE train 1,94 contre 7,11 en val, le réseau a en partie mémorisé les images d'entraînement. Un learning rate trop grand aurait écrasé les filtres appris sur ImageNet à l'étape 1. La MAE val est d'ailleurs déjà à 8,55 dès la première époque, ce qui montre que ces filtres sont bien conservés.

Question 3 : Même si ResNet n'a pas vu de visages à l'entraînement, ses premières couches détectent des contours, des gradients et des textures, qui sont universels et utiles pour n'importe quelle image. Un visage est construit avec ces mêmes briques. Seules les couches profondes sont spécifiques aux objets d'ImageNet, et le fine-tuning permet de les réadapter aux visages.

Expérience 2 : augmentation des données et effet sur le fine-tuning

Question1 : Avec l'augmentation, la MAE test passe de 8,86 à 8,58 ans. Le gain est de 0,28 an, soit environ 3 %, ce qui reste faible.

Question2 : Sans augmentation, à l'epoch 20, la perte train est de 10,67 contre 91,89 en val, soit un écart d'environ 81. Avec augmentation, la figure Fine-tuned ResNet with Data Augmentation, elle est de 20,12 contre 95,30, soit un écart d'environ 75. En MAE, l'écart val moins train passe de 5,2 à 4,5 ans. L'augmentation joue donc bien son rôle de régularisateur. La perte train augmente le modèle n'étant plus capable de mémoriser les images en revanche, le surapprentissage reste important.

Question 3 : La meilleure MAE val est presque identique dans les deux cas on a 7,06 sans augmentation contre 7,11 avec, alors que la MAE test est meilleure de 0,27 an avec augmentation.

Experience3 : à quelle partie du réseau appliquer le fine-tuning ?

Question 1 : Le fine-tuning partiel (layer4.1 + fc) donne 10,70 ans, résultat qui se situe entre le gelé 12,52 et le complet 8,86. Il récupère environ 50 % du gain du fine-tuning complet.

Question 2 : ici, le compromis ne vaut pas vraiment la peine car, on entraîne déjà 4 721 153 paramètres (42 % du réseau) pour la moitié du gain, alors que le réseau complet n'en demande que 2,4 fois plus pour 1,84 an de mieux. Des visages étant différents d'ImageNet, les blocs du milieu ont aussi besoin de s'adapter car comme vu au CM3, domaines diffèrents = plus de couches.

Question 3 : Le fine-tuning complet sera relativement moins bon : 11,2 millions de paramètres pour 500 images aggravent le surapprentissage. Le CM3 dit que le fine-tuning demande plus de données, alors que la version gelée marche avec 50 à 100 images par classe.

Comparaison globale

Methode	Best epoch	Best MAE val	MAE test	params	%
From scratch	19	11,51	13,35	405 889 100	100
Gelé	16	10,58	12,52	513	0,005
Partiel	18	9,07	10,70	4 721 153	42,2
Fine-tune comp	19	7,06	8,86	11 177 025	100
Complet + aug	16	7,11	8,58	11 177 025	100

Sur la figure All Five Approaches Compared, le classement est fine-tuning complet + aug, fine-tuning complet, partiel, gelé, puis from scratch. L'augmentation n'apporte que 0,28 an contre 3,66 ans pour le passage du gelé au fine-tuné, donc le gain vient surtout du transfert. Les meilleures époques sont toutes proches de la fin. Le meilleur compromis est le fine-tuning complet avec augmentation, 17 à 20 % meilleur que le partiel avec seulement 2,4 fois plus de paramètres entraînables, alors que le gelé, le plus, n'améliore la baseline que de 1,9 an contre 5,8 ans pour le meilleur modèle.

Expérience 4 : visualisation des features map

Sur la figure layer1 feature maps (first 16 of 64 channels, les canaux répondent à des choses différentes. De l'observation que je fais, je ne pas tous bien les distinguer mais, le canal situé à la ligne 1, colonne 6 détecte les contours du visage, c'est un détecteur de bords. Le canal situé à la ligne 1, colonne 5 dessine plutôt la zone du visage (bouche, yeux).